ObRail Europe

Mise en œuvre d’un processus ETL répondant au besoin d’une solution I.A

Équipe

BROCHE Cyprien
DURAND Amandine
LACROIX Lohan
ZAABAT Yousra

Promotion B3 2025-2026
Développeur en Intelligence Artificielle et Data Science

epsi
l’école d’ingénierie informatique

Modèle conceptuel et physique des données

Couche Silver (après transformation, schéma en étoile)

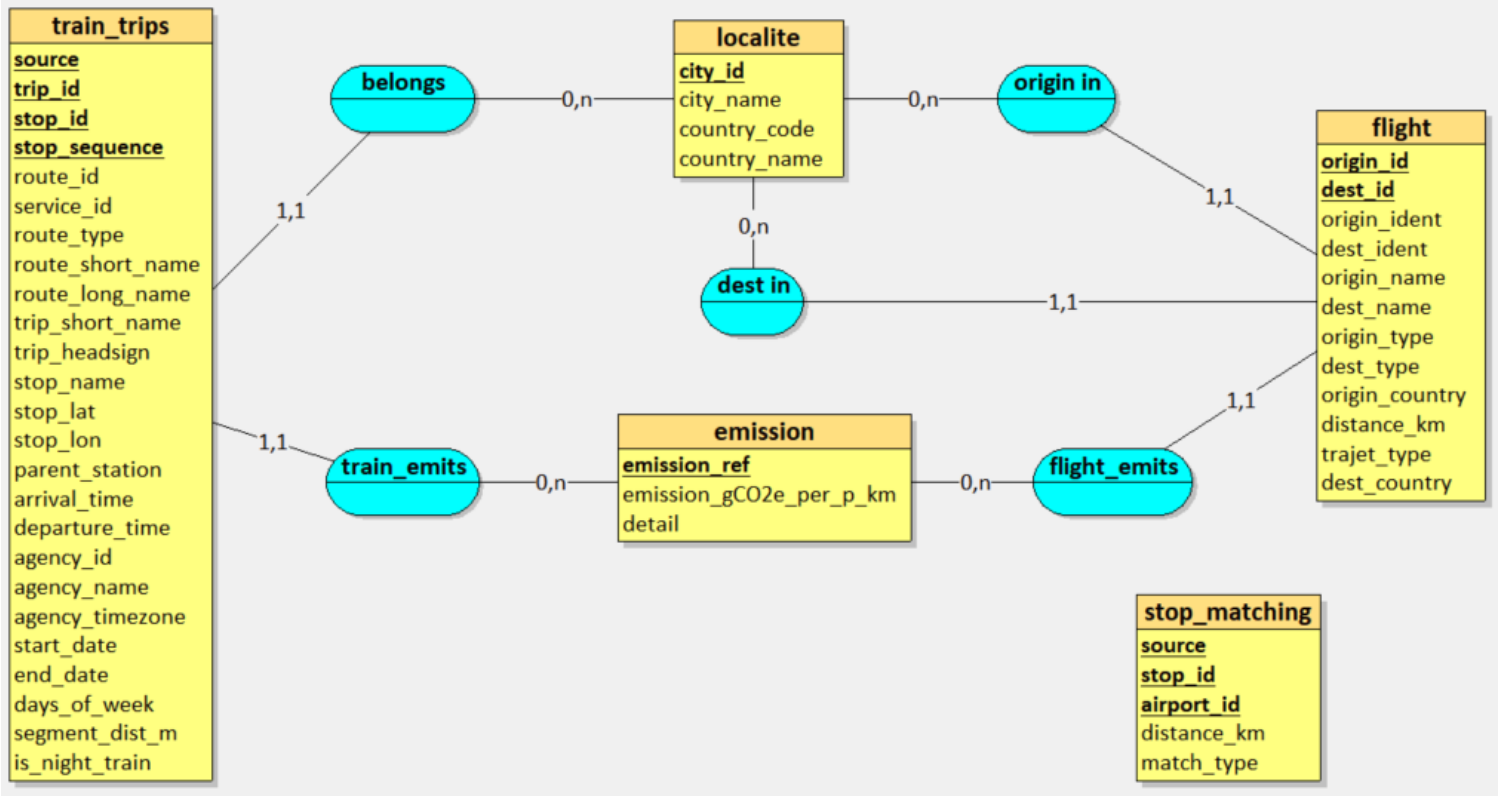

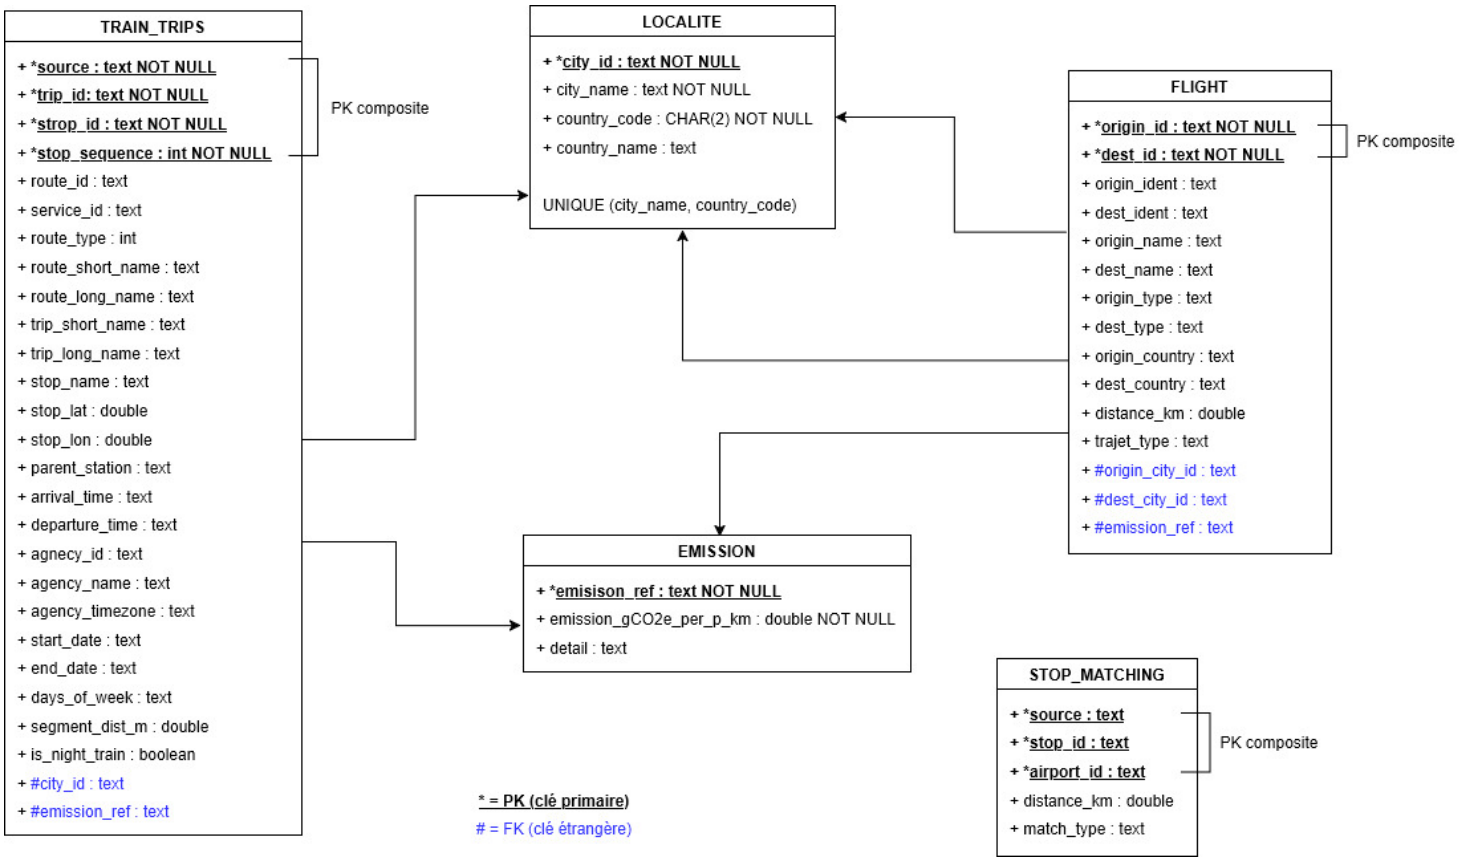

Justifications des entités retenues

L’entité **LOCALITE** est une dimension partagée entre deux tables. Centraliser les villes évite de dupliquer *city_name*/*country_code* dans *train_trips* et dans *flight*, cette dernière l’utilisant deux fois pour l’origine et la destination. Elle sert aussi de pivot pour des requêtes cross-modal : "tous les trajets depuis Paris, train ou avion". La contrainte unique composite sur *city_name* et *country_code* garantit qu'une même ville d’un même pays n'est pas insérée deux fois avec des identifiants différents.

EMISSION est une entité également partagée entre *train_trips* et *flight*. Un même facteur d'émission s'applique à N trajets du même pays × route_type (rail) ou de la même catégorie (aérien). La dénormaliser multiplierait la valeur sur ~38M lignes inutilement. Elle est donc référencée par clé étrangère (FK) depuis les deux tables de faits indépendamment.

TRAIN_TRIPS est une table de faits à granularité arrêt (une ligne = un arrêt dans un trajet), fidèle au format GTFS source. Cela permet de calculer les distances entre arrêts consécutifs (*segment_dist_m*) mais implique qu'une requête origine/destination doit agréger par (*source*, *trip_id*). C'est un compromis volontaire entre fidélité aux données source et simplicité de requête.

FLIGHT est une table de faits à granularité paire d'aéroports. Contrairement à *train_trips*, il n'y a pas d'arrêts intermédiaires dans le modèle aérien, donc la paire (*origin_id*, *dest_id*) est l'unité naturelle. Les deux clés étrangères vers *localite* (*origin_city_id*, *dest_city_id*) permettent de relier chaque aéroport à sa ville indépendamment.

STOP_MATCHING est une table de liaison M:N spatiale entre gares et aéroports. Elle est isolée car la relation n'est pas fonctionnelle : une gare peut être proche de plusieurs aéroports et réciproquement. La garder hors du schéma étoile principal préserve donc sa lisibilité.

Justifications des relations et cardinalités

Relation	Cardinalités	Sens de lecture	Justification
LOCALITE → TRAIN_TRIPS	0,n / 1,1	Une ville peut avoir 0 à N arrêts de train, mais chaque arrêt référence exactement 1 ville	Une même ville (ex: Paris) concentre plusieurs gares et des millions de *stop_sequence*. La FK *city_id* est dans *train_trips* côté 1,1
LOCALITE → FLIGHT (origine)	0,n / 1,1	Une ville peut être l'origine de 0 à N vols, mais chaque vol a exactement 1 ville d'origine	Un aéroport est rattaché à une ville. FK *origin_city_id* est dans *flight*.
LOCALITE → FLIGHT (destination)	0,n / 1,1	Une ville peut être la destination de 0 à N vols, mais chaque vol a exactement 1 ville de destination	Relation symétrique à la précédente, représentée par une deuxième association distincte dans le MCD. FK *dest_city_id* dans *flight*.
EMISSION → TRAIN_TRIPS	0,n / 1,1	Un facteur d'émission couvre 0 à N trajets train, mais chaque trajet référence exactement 1 facteur	Un facteur = 1 pays × 1 *route_type*, partagé par tous les trajets correspondants. FK *emission_ref* dans *train_trips*.
EMISSION → FLIGHT	0,n / 1,1	Un facteur d'émission couvre 0 à N vols, mais chaque vol référence exactement 1 facteur	Un facteur = 1 catégorie de trajet (ex: *small_large_1000km*), partagé par tous les vols de ce type. FK *emission_ref* dans *flight*.

Justifications des contraintes d'intégrité

Type	Table	Données concernées	Description
Clés primaires (PK)	*Localite*	*City_id*	PK artificielle (surrogate) stable et résistante aux homonymes (variations de nommage entre sources)
	Emission	*Emission_ref*	PK naturelle permettant d'encoder les implicitement le type de transport
	Train_trips	*Source, trip_id, stop_id, stop_sequence*	PK composée de 4 colonnes car *trip_id* seul n'est unique qu'au sein d'un feed GTFS. *Source* les disambiguise et *stop_id* + *stop_sequence* garantissent l'unicité de chaque arrêt dans un trajet
	Flight	*Origin_id, dest_id*	PK composée car un vol est défini par sa paire d'aéroports. Un *origin_id* seul peut correspondre à plusieurs destinations.
	Stop_matching	*Source, stop_id, airport_id*	PK composée pour autoriser qu'une même gare soit associée à plusieurs aéroports, et inversement, tout en évitant les doublons d'association
Clé unique (UK)	*Localite*	*City_name, country_code*	UK de couple qui empêche l'insertion de deux entrées ville/pays avec des *city_id* différents. (Note : il existe des villes homonymes dans différents pays)
Nullabilité des clés étrangères (FK)	*Train-trips*	*City_id, emission_ref*	Dans certains cas, ces éléments peuvent manquer (type de train sans facteur d'émissions, arrêt non géocadable). On évite donc le rejet de lignes valides.
	Flight	*Origin_city_id, dest_city_id, emission_ref*	
Absence de FK	*Stop_matching*	*Stop_id, airport_id*	Les deux clés viennent de référentiels différents et rien ne garanti une cohérence stricte au moment du chargement. Des clés étrangères provoqueraient des violations en cascade.